

# Benchmark Comparativo de Algoritmos de Detección de Objetos para el Reconocimiento de Defectos Superficiales en Madera

Ricardo Mauricio Chambilla Perca <sup>a,\*</sup>, Mariel Alison Jara Mamani <sup>a,\*</sup>, Christian Raul Mestas Zegarra <sup>a,\*</sup>,  
Yenaro Joel Noa Camino <sup>a,\*</sup>, Luis Gustavo Sequeiros Condori <sup>a,\*</sup> and Yasiel Pérez Vera <sup>a</sup>

<sup>a</sup> *Escuela Profesional de Ingeniería de Sistemas, Universidad Nacional de San Agustín, esquina con Calle Paucarpata y Vía Rápida Venezuela s/n, Paucarpata 04001, Arequipa, Perú*

---

## Resumen

La inspección automatizada de defectos superficiales en madera enfrenta desafíos derivados del severo desequilibrio de clases en distribuciones de cola larga y de la alta variabilidad intraclase de las anomalías orgánicas. Este artículo presenta un benchmark comparativo que evalúa la intersección de tres paradigmas de detección de objetos: una etapa, dos etapas y transformers con cuatro estrategias de aumento de datos: sin augmentación, Albumentations con balanceo de clases, BoxAug con transformaciones de ruido, y BoxAug con armonización neuronal mediante LibCom. El estudio se ejecuta sobre un dataset de 4,000 imágenes con 8,888 anotaciones distribuidas en 8 categorías de defectos, empleando un pipeline reproducible de cinco etapas con caché por pasos. Los resultados experimentales demuestran que RF-DETR alcanza la mayor precisión de ranking con mAP@0.5 de 0.717 bajo umbrales de confianza calibrados por modelo, mientras que Cascade R-CNN con BoxAug LibCom alcanza el mejor F1 de punto operativo de 0.798. Los efectos del aumento dependen del paradigma: BoxAug LibCom mejora Cascade R-CNN en +0.033 mAP@0.5, mientras que las tres estrategias de aumento dejan a YOLO26 en o por debajo de su baseline sin aumento (0.592 a 0.604 frente a 0.618). El análisis por clase en AP@0.5 muestra que médula alcanza 0.910 mientras que cuarcita llega a 0.550 como máximo, confirmando que la distinguibilidad visual interactúa con la frecuencia de clase. Se discuten el protocolo de umbrales calibrados y la respuesta al aumento dependiente del paradigma, y se proponen direcciones futuras incluyendo presupuestos de entrenamiento extendidos y aumento basado en difusión.

*Palabras clave:* detección de defectos, visión por computadora, aprendizaje profundo, procesamiento de madera, benchmark comparativo

---

## 1. Introducción

La manufactura industrial moderna depende de sistemas de control de calidad automatizados

para mantener la eficiencia operativa y reducir costos en las cadenas de suministro [1]. La integración de tecnologías de visión por computadora y aprendizaje automático ha transformado los

---

\* Autores correspondientes.

Correo electrónico: [rchambillap@unsa.edu.pe](mailto:rchambillap@unsa.edu.pe) 

Correo electrónico: [mjarama@unsa.edu.pe](mailto:mjarama@unsa.edu.pe) 

Correo electrónico: [cmestasz@unsa.edu.pe](mailto:cmestasz@unsa.edu.pe) 

Correo electrónico: [ynoa@unsa.edu.pe](mailto:ynoa@unsa.edu.pe) 

Correo electrónico: [lsequeiros@unsa.edu.pe](mailto:lsequeiros@unsa.edu.pe) 

procesos de inspección industrial, permitiendo la detección de anomalías con velocidades y niveles de precisión que superan a los métodos manuales [2]. La automatización de la inspección de calidad se ha convertido en un componente esencial de la Industria 4.0, particularmente en sectores donde la variabilidad del material natural dificulta la estandarización de los procesos productivos [3]. La industria maderera representa un sector económico significativo a nivel global, donde la madera se constituye como un recurso renovable de alta importancia tanto estructural como comercial [4]. El procesamiento de madera involucra múltiples etapas que van desde el aserrado hasta el acabado final, y en cada una de ellas la calidad del material determina directamente su valor y aplicabilidad [5]. El aprovechamiento total de la madera en procesos productivos alcanza únicamente entre el 50% y el 70% del volumen, debido a la presencia de defectos que deben ser identificados y removidos [5]. Esta tasa de desperdicio resalta la necesidad urgente de sistemas de inspección más eficientes que permitan maximizar el aprovechamiento del recurso [6]. La integración de estos sistemas en plantas automatizadas se coordina con brazos robóticos y celdas de manipulación autónoma de material [7].

El reconocimiento automatizado de defectos superficiales en madera presenta desafíos técnicos específicos que lo distinguen de otras aplicaciones de detección de objetos [8]. Las anomalías superficiales abarcan nudos vivos, nudos muertos, grietas de secado, bolsas de resina, manchas de hongo y daños mecánicos [5]. La alta varianza intraclase de los defectos, donde un mismo tipo de anomalía puede presentar apariencias visuales muy diferentes, constituye uno de los principales obstáculos [9]. El bajo contraste entre ciertos defectos y la veta de la madera sana dificulta la segmentación precisa de las regiones anómalas [10]. Las condiciones de iluminación variables en los entornos de los aserraderos, combinadas con la velocidad de las líneas de producción que pueden alcanzar valores de 9.6 m/s, imponen requisitos estrictos sobre los tiempos de inferencia de los algoritmos de detección [9].

Adicionalmente, los datasets industriales sufren un severo desequilibrio de clases en distribución de cola larga, donde defectos raros como médula o nudos faltantes quedan subrepresentados frente a la alta prevalencia de nudos estándar [9]. Estos factores convergen en un problema de investigación que requiere soluciones algorítmicas especializadas de alta localización espacial y baja latencia [11].

Históricamente, la inspección de defectos en madera dependió de personal capacitado que examinaba visualmente las superficies en busca de imperfecciones [6]. Este enfoque manual presenta limitaciones significativas en términos de velocidad, consistencia y escalabilidad [6]. La fatiga visual del operador, la subjetividad en la evaluación y la incapacidad para procesar grandes volúmenes de material en tiempo real son problemas recurrentes que afectan la fiabilidad del proceso [6]. Estudios previos han demostrado que la inspección manual rara vez supera el 70% de acierto en entornos industriales de alta velocidad [9]. Para superar estas deficiencias, el estado del arte evolucionó progresivamente desde sistemas basados en sensores optoelectrónicos y visión por computadora clásica [12]. Los enfoques clásicos utilizaban técnicas de procesamiento de imágenes como matrices de coocurrencia de niveles de gris, patrones binarios locales y descriptores de gradientes orientados (HOG) [13], combinados con clasificadores de máquinas de vectores de soporte (SVM) [14], [15]. El marco de trabajo Viola-Jones [16] representó un avance pionero en la detección de objetos en tiempo real mediante características de tipo Haar [17] y clasificadores en cascada AdaBoost [18]. El emparejamiento de imágenes evolucionó desde descriptores diseñados manualmente (SIFT, SURF, HOG) hacia representaciones jerárquicas profundas [19]. Sin embargo, si bien estos métodos clásicos ofrecen interpretabilidad, su capacidad para manejar la alta variabilidad natural y el bajo contraste de los defectos superficiales orgánicos en la madera resulta severamente limitada [11].

La transición hacia redes neuronales profundas convolucionales (CNN) ha permitido la ex-

tracción automática de características jerárquicas que capturan patrones espaciales complejos [20]. El ecosistema tecnológico contemporáneo ofrece marcos de trabajo para el desarrollo de detectores profundos de alto rendimiento [21]. Las arquitecturas basadas en convoluciones profundas evolucionaron a través de detectores regionales de dos etapas como Faster R-CNN [22] y Mask R-CNN [23], así como detectores de una etapa basados en anclajes como Single Shot MultiBox Detector (SSD) [24], Feature Pyramid Networks (FPN) [25] y modelos libres de anclajes como FCOS [26]. La familia YOLO impulsó la detección en tiempo real desde sus primeras versiones YOLOv1 [27], YOLOv2 [28], YOLOv3 [29], YOLOv4 [30], hasta revisiones completas del paradigma YOLOv1 a YOLOv8 [31]. Más recientemente, los modelos basados en Vision Transformers (ViT) introdujeron mecanismos de autoatención global que capturan dependencias espaciales de largo alcance en inspección visual industrial [32].

Frente a los descriptores clásicos y detectores heredados, el estado del arte actual demanda la evaluación rigurosa de paradigmas profundos de última generación combinados con técnicas de balanceo sintético de datos. Las arquitecturas convolucionales avanzadas como Cascade R-CNN [33] proporcionan refinamiento multietapa de cajas delimitadoras, mientras que YOLO26 [34] incorpora un diseño de cabeza dual para inferencia end-to-end en tiempo real sin etapa NMS y optimizador MuSGD [34]. En el dominio de transformers, RF-DETR [35] establece la frontera de precisión y latencia mediante búsqueda de arquitectura neuronal [35]. En paralelo, las técnicas de aumento de objetos (BoxAug [36], Simple Copy-Paste [37]) integradas con frameworks de composición profunda y armonización neuronal (LibCom [38], PCT-Net [39], Latent Bridge Matching [40]) permiten mitigar el desequilibrio de clases sin introducir artefactos visuales. El objetivo principal de este artículo es proporcionar una evaluación matricial de 3 por 4 que intersecta estos tres paradigmas profundos con cuatro estrategias de aumento de datos en

el reconocimiento de defectos superficiales en madera.

El resto del artículo se organiza de la siguiente manera. La 2. presenta los trabajos relacionados con la detección de defectos en madera utilizando técnicas de aprendizaje profundo. La 3. describe los materiales y métodos utilizados, incluyendo los fundamentos teóricos, las herramientas y tecnologías empleadas, las características del dataset y el método propuesto para el desarrollo. La 4. detalla los resultados obtenidos, incluyendo métricas de rendimiento y análisis comparativo. La 5. interpreta los hallazgos principales, comparándolos con la literatura existente y analizando las interacciones entre arquitecturas y estrategias de aumento. La 6. resume las contribuciones del estudio. Finalmente, la 7. presenta trabajos futuros y posibles extensiones de la investigación.

## 2. Trabajos relacionados

Urbonas et al. [41] abordaron la identificación automatizada de defectos en superficies de chapa de madera utilizando la arquitectura Faster R-CNN con técnicas de aprendizaje por transferencia y aumento de datos. El objetivo fue evaluar la viabilidad de redes regionales propuestas preentrenadas para la detección de defectos en un entorno industrial controlado. El aporte principal fue demostrar que el aprendizaje por transferencia con modelos ResNet152 alcanza una precisión del 96.1% en la clasificación combinada de defectos. La metodología empleó cuatro redes neuronales preentrenadas, AlexNet, VGG16, BNInception y ResNet152, con aumento de datos por rotación y volteo. Los resultados mostraron que ResNet152 obtuvo el mejor rendimiento con 80.6% de precisión en clasificación de defectos individuales. Como deficiencia, el estudio se limitó a un dataset de 4,729 imágenes con solo 353 muestras defectuosas, lo que restringió la generalización de los resultados.

Fang et al. [42] propusieron un sistema automatizado para la detección precisa de nudos superficiales en madera aserrada utilizando el modelo YOLO-v5. El objetivo fue desarrollar

un detector en tiempo real capaz de identificar múltiples tipos de nudos con alta precisión. El aporte fue la validación de YOLO-v5 como alternativa eficiente a los detectores de dos etapas para la inspección de madera. La metodología consistió en el fine-tuning de YOLO-v5 con dos datasets de nudos de madera, evaluando métricas de precisión, recall y F1-score. Los resultados alcanzaron un F-Score del 91.7% en el primer dataset y del 97.7% en el segundo, superando a YOLO-v3 SPP y Faster R-CNN en velocidad y tamaño de modelo. La deficiencia identificada fue que el modelo se evaluó únicamente en la clase de nudos, sin considerar otros tipos de defectos como grietas o manchas.

Han et al. [43] presentaron una versión mejorada del algoritmo YOLOv5 para la detección de defectos superficiales en madera, incorporando mecanismos de atención en la arquitectura. El objetivo fue mejorar la capacidad del modelo para detectar defectos pequeños y de bajo contraste. El aporte principal fue la integración de módulos de atención que permiten al modelo enfocarse en regiones relevantes de la imagen. La metodología modificó la backbone y el neck de YOLOv5 con capas de atención espacial y de canal. Los resultados demostraron mejoras significativas en la detección de defectos pequeños comparado con el modelo base. La deficiencia fue la falta de una comparación estandarizada con otros detectores estado del arte en el mismo dataset.

Zheng et al. [44] desarrollaron GBCD-YOLO, un modelo ligero y de alta precisión para la detección de defectos en madera, basado en modificaciones arquitectónicas de YOLOv5s. El objetivo fue reducir la complejidad computacional manteniendo la precisión de detección. El aporte fue la combinación de bloques Ghost Bottleneck, atención BiFormer, upsampling CA-RAFE y dinámica DyHead con pérdida CIOU. La metodología incluyó optimización de la arquitectura y evaluación en un dataset de defectos de madera con 10 categorías. Los resultados mostraron un mAP@0.5 del 88.72%, una mejora del 13.45% sobre YOLOv5s base, con reducción

del 15.49% en parámetros y aumento del 6.25% en FPS. La deficiencia fue que el modelo no se comparó con arquitecturas basadas en transformers o detectores de dos etapas.

Zheng et al. [45] propusieron CWB-YOLOv8, una mejora del algoritmo YOLOv8 mediante la incorporación de Convolución Condicional Paramétrica, Wise-IoU y BiFormer para la detección de defectos en madera. El objetivo fue mejorar la capacidad de detección de defectos variados en tamaño y apariencia. El aporte principal fue la combinación de tres módulos que mejoran la extracción de características, la función de pérdida y la atención multi-escala. La metodología empleó un dataset personalizado de 6,134 imágenes con defectos de especies de pino radiata, eucalipto y árbol de Tuna. Los resultados alcanzaron un mAP@0.5 del 89.2%, con mejoras del 3.5% sobre YOLOv8 estándar y detección precisa de grietas con 96% de recall y resina con 93% de recall. La deficiencia fue la ausencia de evaluación de métricas de eficiencia computacional como latencia en tiempo real.

Sun [46] implementó un sistema de detección de defectos de calidad en madera basado en aprendizaje profundo y un framework multicriterio. El objetivo fue desarrollar un sistema que combinara la detección automática de defectos con un sistema de evaluación multicriterio para la clasificación de calidad. El aporte fue la integración de un framework de decisión multicriterio con redes neuronales profundas para la evaluación integral de la calidad de la madera. La metodología utilizó CNN para la detección de defectos internos combinado con análisis multicriterio para la clasificación de calidad. Los resultados reportaron una tasa de detección del 99.8% para defectos internos y un IOU promedio del 74.3%. La deficiencia fue que el estudio se enfocó en defectos internos sin una validación extensiva en datasets públicos de referencia.

Kilic et al. [47] presentaron WD Detector, un diseño híbrido de sensor basado en aprendizaje profundo para la detección de defectos en madera, que combina extracción de caracterís-

ticas con CNN y clasificadores de aprendizaje automático clásico. El objetivo fue desarrollar un sistema híbrido que aproveche las fortalezas tanto del aprendizaje profundo como del aprendizaje automático tradicional. El aporte fue la demostración de que la combinación de características extraídas por Xception con clasificadores como CatBoost supera a las CNN puras. La metodología empleó Xception para la extracción de características y 12 clasificadores de ML para la clasificación final. Los resultados alcanzaron una precisión del 99.32% con CatBoost como el mejor clasificador. La deficiencia fue que el sistema requiere un pipeline de dos etapas que incrementa la complejidad de implementación.

Ji et al. [48] desarrollaron un algoritmo basado en aprendizaje profundo para la detección en línea de defectos de objetivo pequeño en madera aserrada de gran tamaño. El objetivo fue resolver el problema de detectar defectos pequeños en imágenes de alta resolución de tableros industriales. El aporte fue la integración de red ELAN (Efficient Layer Aggregation Network) con YOLO y costura de imágenes mediante SIFT para manejar el procesamiento de madera de gran formato. La metodología combinó detección de keypoints SIFT para la unión de imágenes con una arquitectura YOLO modificada para la detección de defectos pequeños. Los resultados reportaron una precisión del 90.37% con una velocidad de procesamiento de 40 m/min. La deficiencia fue la dependencia del algoritmo SIFT para la costura de imágenes, que puede ser computacionalmente costosa en entornos de alta velocidad.

Wolszczak et al. [49] abordaron la detección de manchas azules causadas por hongos en un sistema de inspección de madera en aserraderos, utilizando redes neuronales entrenadas para la clasificación automática de este tipo específico de defecto. El objetivo fue desarrollar un sistema automatizado capaz de identificar manchas azules en superficies de madera durante el proceso de producción. El aporte fue la aplicación específica de redes neuronales para un tipo de defecto particularmente difícil de detectar por métodos

tradicionales. La metodología empleó una red neuronal entrenada con imágenes de manchas azules capturadas en un entorno industrial real. Los resultados demostraron la viabilidad del enfoque para la detección automatizada de este tipo de defecto. La deficiencia fue que el estudio se limitó a una sola categoría de defecto sin evaluar el rendimiento en un escenario multi-clase.

Chen et al. [50] propusieron un sistema de detección de defectos en paneles de madera encolada utilizando técnicas de aprendizaje profundo. El objetivo fue desarrollar un sistema WDD-DL que combinara filtros de procesamiento de imágenes con clasificación por redes neuronales. El aporte fue la combinación de filtros de Gabor, detección de esquinas de Harris y morfología matemática con la red InceptionResNetV2 para la clasificación. La metodología implementó un pipeline de dos etapas: pre-procesamiento con filtros clásicos y clasificación con CNN. Los resultados alcanzaron una precisión de 0.97, un recall de 0.90 y un F1-score de 0.92. La deficiencia fue la complejidad del pipeline de dos etapas que dificulta la implementación en tiempo real.

Shah et al. [8] realizaron una revisión comprehensiva de la detección automática de defectos en inspección de superficies de madera, comparando modelos de una etapa (YOLO y variantes) y de dos etapas (Faster R-CNN), e investigando enfoques emergentes de aprendizaje zero-shot. El objetivo fue proporcionar una visión general del estado del arte en detección de defectos de madera. El aporte fue la comparación sistemática de modelos una etapa y dos etapas, más la introducción de enfoques zero-shot basados en modelos visión-lenguaje como CLIP. La metodología revisó literatura reciente, analizó datasets públicos y comparó métricas de rendimiento. Los resultados mostraron que los modelos YOLO son preferidos para aplicaciones en tiempo real, mientras que Faster R-CNN ofrece mayor precisión a costa de velocidad. La deficiencia fue que la revisión no incluyó modelos basados en transformers como representantes de la nueva generación de detectores. La Tabla 1

Tabla 1: Resumen comparativo de trabajos relacionados con detección de defectos en madera.

| Autor                 | Enfoque                    | Métrica principal       | Deficiencia                      |
|-----------------------|----------------------------|-------------------------|----------------------------------|
| Urbonas et al. [41]   | Faster R-CNN + TL          | 96.1% acc.              | Dataset pequeño                  |
| Fang et al. [42]      | YOLO-v5                    | 97.7% F1                | Solo nudos                       |
| Han et al. [43]       | YOLOv5 + atención          | Mejora sobre base       | Sin comparación                  |
| Zheng et al. [44]     | GBCD-YOLO                  | 88.7% mAP               | Sin transformers                 |
| Zheng et al. [45]     | CWB-YOLOv8                 | 89.2% mAP               | Sin eficiencia                   |
| Sun [46]              | CNN + multicriterio        | 99.8% det.              | Dataset limitado                 |
| Kilic et al. [47]     | Xception + ML              | 99.3% acc.              | Pipeline dos etapas              |
| Ji et al. [48]        | YOLO + ELAN + SIFT         | 90.4% acc.              | Dependencia SIFT                 |
| Wolszczak et al. [49] | Red neuronal               | Clasif. binaria         | Una sola clase                   |
| Chen et al. [50]      | Filtros + InceptionRes-Net | 0.92 F1                 | Pipeline complejo                |
| Shah et al. [8]       | Revisión general           | Comparación cualitativa | Sin benchmark matricial empírico |

resume los trabajos revisados en la literatura. Ninguno de los estudios existentes evalúa la matriz cruzada entre los tres paradigmas de detección y las técnicas avanzadas de aumento por objeto con armonización neuronal bajo desequilibrio severo de clases.

### 3. Materiales y Métodos

#### 3.1. Fundamentos teóricos

La formación de defectos superficiales en la madera responde a factores fisiológicos del árbol y a tensiones mecánicas durante el procesamiento [4]. Los nudos vivos corresponden a bases de ramas integradas en el tejido leñoso, mientras que los nudos muertos representan ramas separadas que generan cavidades discontinuas [5]. Las grietas se originan por tensiones de tracción perpendicular durante las fases de secado del material [4]. Las acumulaciones de resina, la médula central y las inclusiones minerales de cuarcita alteran la homogeneidad física de la superficie [5]. Las líneas de producción modernas trasladan los tablones cepillados a velocidades lineales de 9.6 m/s ante cámaras de escaneo lineal [9]. El tiempo disponible para capturar, procesar y clasificar cada imagen se restringe a intervalos de pocos milisegundos [9]. La alta variabilidad

en el grano de la madera de fondo disminuye el contraste visual de las regiones defectuosas [5].

La recolección de datos en entornos industriales produce conjuntos anotados con un severo desequilibrio de clases [51]. En una distribución de cola larga, una fracción reducida de categorías acapara la mayoría de las observaciones [51]. El ratio de desequilibrio mide la relación entre la frecuencia de la clase mayoritaria y la clase minoritaria. En conjuntos con un ratio superior a 30, las funciones de pérdida estándar quedan dominadas por los gradientes de las categorías dominantes [52]. La red neuronal suprime las predicciones de las categorías raras al asignarles puntajes de confianza deficientes [53]. Este fenómeno provoca un colapso en la capacidad discriminativa del modelo sobre anomalías poco frecuentes pero estructuralmente peligrosas [54].

El aumento de datos a nivel de objeto modifica directamente la distribución de frecuencias de las clases anotadas [36]. A diferencia de las transformaciones afines globales, la técnica BoxAug aísla parches recortados pertenecientes a categorías de la cola [36]. Los parches son multiplicados aplicando transformaciones estocásticas de escala, rotación y volteo horizontal [36]. Mediante

el procedimiento Simple Copy-Paste, los parches transformados se reinsertan en imágenes de entrenamiento con baja densidad de defectos [37]. Para eliminar las discontinuidades visuales del pegado directo, el framework LibCom proporciona algoritmos de composición profunda [38]. El modelo PCT-Net estima transformaciones de color a nivel de píxel para igualar la luminancia regional [39]. El método Latent Bridge Matching aplica un mapeo en espacio latente para generar sombras y adaptaciones fotométricas en un solo paso de inferencia [40]. Las muestras sintéticas resultantes preservan las etiquetas de ubicación a la vez que ofrecen coherencia fotométrica con la madera receptora [55].

Cascade R-CNN representa la arquitectura convolucional de dos etapas orientada a alta precisión espacial [33]. La primera etapa emplea una Red de Propuesta de Regiones para seleccionar candidatos sobre mapas de características convolucionales. La segunda etapa ejecuta una secuencia de cabezales de detección entrenados con umbrales de Intersección sobre Unión progresivamente más estrictos. Este diseño en cascada refina gradualmente las coordenadas de las cajas delimitadoras y minimiza los falsos positivos en escenarios de alta densidad de defectos [33]. El costo computacional asociado al refinamiento multietapa se traduce en tiempos de inferencia mayores respecto a detectores de una etapa, pero la ganancia en precisión de localización justifica su aplicación en escenarios donde la tasa de falsos positivos es crítica [33].

YOLO26 representa la arquitectura convolucional de una etapa diseñada para inferencia en tiempo real [34]. Adopta una formulación libre de anclajes que predice directamente los centros y dimensiones de las cajas delimitadoras desde mapas de características multiescala. Su diseño de cabeza dual elimina la necesidad de la etapa de supresión de no máximos en la inferencia, optimizando la velocidad de procesamiento y la latencia computacional [34]. La ausencia de la etapa NMS reduce significativamente el tiempo de post-procesamiento, lo cual es ventajoso para aplicaciones en tiempo real donde cada milise-

gundo es crítico [34]. Sin embargo, la arquitectura de una etapa puede ser más susceptible a la falta de datos de entrenamiento en comparación con los detectores de dos etapas.

RF-DETR representa la arquitectura basada en Vision Transformers optimizada para detección en tiempo real [35]. Utiliza mecanismos de autoatención global bidireccional para capturar dependencias espaciales de largo alcance a lo largo de toda la superficie de la imagen [56]. Mediante Búsqueda de Arquitectura Neuronal, RF-DETR descubre configuraciones estructurales óptimas en la frontera de Pareto entre precisión de localización y latencia de procesamiento [35]. A diferencia de los detectores puramente convolucionales, los transformers procesan la imagen completa mediante tokenización y capas de autoatención, lo que les permite modelar relaciones globales entre regiones distantes [56]. Esta capacidad resulta particularmente relevante para la inspección de madera, donde los defectos pueden distribuirse de manera dispersa a lo largo de la superficie del tablón.

La cuantificación del rendimiento de los detectores de objetos integra métricas de precisión espacial y eficiencia computacional [8]. La precisión mide la proporción de predicciones positivas correctas, mientras que el recall evalúa la proporción de defectos reales detectados [8]. El puntaje F1 representa la media armónica de ambas métricas. La Intersección sobre Unión evalúa la superposición espacial entre la caja predicha y la anotación real. La precisión promedio media  $mAP@0.5$  y  $mAP@0.5:0.95$  agrega el rendimiento a través de múltiples umbrales de superposición, aislando las fortalezas algorítmicas en clases desequilibradas [8]. Las métricas de eficiencia computacional comprenden el tiempo de inferencia expresado en milisegundos por imagen, el rendimiento en cuadros por segundo, el número de parámetros flotantes en millones y el tamaño del modelo almacenado en disco en megabytes [11].

### 3.2. Herramientas y Tecnologías

El desarrollo del pipeline de experimentación se ejecuta sobre el lenguaje de programación Python en su versión 3.12. El framework de aprendizaje profundo principal corresponde a PyTorch versión 2.7.0 con aceleración por GPU mediante bibliotecas CUDA 12.8. Las operaciones suplementarias de visión computacional emplean torchvision versión 0.22.0. La arquitectura Cascade R-CNN se implementa mediante la librería MMDetection versión 3.2.0, soportada por MMCV versión 2.2.0 y MMEEngine versión 0.10.7. El detector YOLO26 se ejecuta utilizando el marco Ultralytics en su versión 8.2.0. La arquitectura RF-DETR se compila desde el motor oficial RF-DETR versión 1.3.0.

El procesamiento de datos sintéticos y aumentos fotométricos utiliza Albumentations versión 1.4.0. Las primitivas de composición e inserción de objetos emplean la librería LibCom versión 0.2.0 integrada en el entorno de desarrollo. La gestión estricta de configuraciones de la tubería se programa mediante Pydantic versión 2.6.1. La manipulación acelerada de tablas de metadatos utiliza Polars versión 1.43.0 y OpenCV versión 5.0.0. El entorno virtual y la resolución de dependencias se administran mediante el gestor uv versión 0.6+. Todos los modelos fueron entrenados y evaluados en una GPU NVIDIA RTX 5070 Ti, lo cual establece el punto de referencia para las mediciones de tiempo de inferencia y rendimiento computacional reportadas en este estudio.

### 3.3. Dataset

El estudio utiliza la versión filtrada y anotada en formato YOLO disponible en Kaggle [57], derivada del conjunto de datos original Large-scale Image Dataset of Wood Surface Defects publicado por Kodytek et al. [9]. El dataset original fue adquirido en un entorno industrial real durante la producción de un aserradero mediante una cámara de escaneo lineal JAI SW-4000TL-PMCL a una frecuencia de línea de 66 kHz [9]. La versión filtrada empleada en este trabajo [57] ha sido preprocesada para incluir

exclusivamente imágenes que contienen defectos y sus anotaciones han sido convertidas al formato YOLO estándar para la evaluación directa de modelos de detección de objetos. El dataset filtrado contiene un total de 4,000 imágenes en formato JPG con una resolución espacial fija de 2800 por 1024 píxeles [57]. El conjunto almacena 8,888 cajas delimitadoras anotadas distribuidas en 8 categorías de defectos superficiales, promediando 2.22 defectos por imagen. La Figura 1 ilustra la distribución porcentual de frecuencia para cada clase de defecto.

Las anotaciones proporcionan coordenadas normalizadas de cajas delimitadoras en formato YOLO. La distribución de clases refleja las condiciones reales de producción industrial [9]. Las categorías mayoritarias corresponden a nudos vivos con 3,949 anotaciones, siendo el 44.4%, y nudos muertos con 2,865 anotaciones, siendo el 32.2%, combinando el 76.6% del conjunto. Las categorías intermedias incluyen resina con 642 anotaciones, siendo el 7.2%, grietas con 509 anotaciones, siendo el 5.7%, y nudos con grietas con 463 anotaciones, siendo el 5.2%. Las categorías minoritarias comprenden médula con 204 anotaciones, siendo el 2.3%, cuarcita con 144 anotaciones, siendo el 1.6%, y nudos faltantes con 112 anotaciones, siendo el 1.3%. El ratio de desequilibrio calculado alcanza un valor aproximado de 35.3. La Figura 2 muestra ejemplos representativos de las ocho categorías de defectos anotadas en el conjunto de datos.

### 3.4. Método propuesto

El método propuesto implementa un pipeline de experimentación de cinco etapas diseñado para garantizar la reproducibilidad y la comparabilidad justa entre configuraciones. Las etapas comprenden: (1) preparación de datos, (2) aumento de datos, (3) entrenamiento de modelos, (4) evaluación y (5) análisis de resultados. Figura 3 resume el flujo con la operación esencial de cada etapa; el texto detalla parámetros y decisiones de diseño. La configuración de toda la tubería se gestiona mediante modelos Pydantic tipados que garantizan la validación de parámetros en tiempo de compilación [58]. La interfaz




Figura 1: Distribución de clases de defectos en el dataset filtrado [57].

de línea de comandos permite la personalización de cualquier parámetro anidado mediante notación de puntos, facilitando la experimentación reproducible. Todos los generadores aleatorios (Python, NumPy, PyTorch) se siembran desde una semilla maestra con identificadores de flujo fijos por etapa; sin embargo, cudnn benchmarking y TF32 permanecen activos.

La etapa de preparación de datos aplica tres operaciones secuenciales sobre el dataset crudo. Primero, se recortan los bordes negros mediante segmentación por umbralización de Otsu [59] y operaciones morfológicas de cierre, aislando la región válida del tablón de madera. Segundo, las

imágenes se reducen a la mitad de su resolución original mediante interpolación de área. Tercero, las anotaciones de cajas delimitadoras se transforman al espacio coordinado resultante y se filtran con una compuerta de tamaño de tres reglas (dimensión absoluta mínima de 2.0 px salvo que el área alcance 12.0 px<sup>2</sup> o la dimensión mayor alcance 6.0 px, preservando grietas delgadas y descartando motas inservibles). El conjunto resultante se particiona en entrenamiento con 80%, validación con 10% y prueba con 10% mediante estratificación iterativa codiciosa que preserva la distribución de clases en cada partición [60]. Para aliviar el desequilibrio, se descartan luego el 35% de los tableros de entrenamiento que




Figura 2: Ejemplos de las ocho clases de defectos anotadas en el dataset de madera [57].




Figura 3: Pipeline experimental propuesto de cinco etapas.

contienen solo las dos clases mayoritarias; esto desplaza intencionalmente los priors de entrenamiento respecto a las distribuciones naturales de validación y prueba, por lo que se esperan puntajes reducidos en clases mayoritarias aun cuando el balanceo funcione.

Se evaluaron tres estrategias de aumento diseñadas para mitigar el desequilibrio de clases, dirigidas a alcanzar una proporción del 33% entre la clase minoritaria y la mayoritaria. Cada estrategia agranda el conjunto de entrenamiento sintetizando instancias de clases minoritarias, por lo que los tamaños de entrenamiento aumentado difieren del original por diseño y el tamaño se reporta por estrategia. Para la comparativa entre los paradigmas, se configuraron tres arquitecturas representativas de cada enfoque de detección de objetos. La evaluación se realiza en el conjunto de prueba de 400 imágenes utilizando mAP@0.5 y mAP@0.5:0.95 estándar COCO, AP@0.5 por clase, y precisión, recall y F1 de punto operativo en umbrales de confianza calibrados por modelo. El tiempo de inferencia se mide promediando el tiempo total de procesamiento sobre todas las imágenes del conjunto de prueba.

La incertidumbre por clase se cuantifica en los mismos puntos operativos. Para cada clase  $c$ , los conteos de TP, FP y FN provienen del emparejamiento voraz de punto operativo con  $\text{IoU} \geq 0.5$ , y la precisión y el recall por clase se

tratan como proporciones binomiales; la cobertura simultánea del 95% a nivel familiar sobre las  $K = 8$  clases de defecto se obtiene con la corrección de Bonferroni, reportando cada clase con un intervalo de Wilson al nivel  $1 - 0.05/8 = 99.375\%$  ( $z = 2.73$ ), es decir  $\text{IC}_c = \text{Wilson}(x_c, n_c; z_{\{1-0.05/16\}})$ , con un guion cuando  $n_c = 0$ . Dado que el emparejamiento se restringe a la misma clase, una etiqueta cruzada errónea aparece como un falso positivo de la clase predicha más un falso negativo de la clase verdadera en lugar de una entrada fuera de la diagonal de confusión.

Todas las arquitecturas se entrenan con ponderación por clase de número efectivo [52] inyectada en la pérdida de clasificación de cada modelo. Si bien técnicas como Focal Loss [61] y Seesaw Loss [54] apuntan al mismo desequilibrio, el estudio fija un único tratamiento a nivel de pérdida para que los efectos del aumento sigan siendo atribuibles, dejando estrategias de pérdida alternativas como trabajo futuro. Cada modelo se evalúa en su propio punto operativo calibrado infiriendo a su propia resolución de entrenamiento, de modo que ni el manejo del tamaño de entrada ni un umbral de confianza fijo pueden favorecer a ningún paradigma.

Albumentations con balanceo de clases emplea seis transformaciones activas a nivel de píxel con las siguientes probabilidades de aplicación: volteo horizontal a 0.5, volteo vertical a 0.5, ro-

tación-escala-traslación a 0.5, contraste y brillo aleatorios a 0.4, variación de color a 0.3 y desenfoque gaussiano a 0.2. La generación del dataset identifica las clases raras por debajo del umbral objetivo y aumenta selectivamente las imágenes que las contienen, agregando las imágenes sintetizadas al conjunto de entrenamiento.

BoxAug estándar implementa un enfoque de recorte y pegado de objetos. Para cada clase rara, recorta instancias de un banco de objetos construido previamente, aplica transformaciones estocásticas a nivel de parche, incluyendo jitter de escala entre 0.8 y 1.2, rotación, volteo, recorte aleatorio, diferentes tipos de ruido, y operaciones morfológicas, y las pega en posiciones espaciales válidas calculadas a partir de guías de ubicación por clase. Cada corrida regenera desde una copia limpia de la partición de entrenamiento y acumula los pegados en memoria antes de escribir, con reintentos de ubicación acotados que fallan ante agotamiento. Las guías espaciales codifican conocimiento del dominio: por ejemplo, los nudos faltantes tienden a localizarse en los bordes de la imagen, mientras que la cuarcita aparece predominantemente en la región central.

BoxAug con LibCom utiliza el mismo procedimiento de recorte y pegado que BoxAug estándar, pero reemplaza la inserción directa por composición profunda mediante la librería LibCom [38]. Las operaciones de borde emplean modos de armonización neuronal que eliminan las discontinuidades visuales en los márgenes entre el fondo y la imagen superpuesta. Las transformaciones geométricas se limitan a jitter de escala y volteo horizontal/vertical, excluyendo transformaciones de ruido a nivel de píxel.

Cascade R-CNN representa al paradigma de dos etapas. Posee una arquitectura convolucional basada en ResNet-50 con Feature Pyramid Network (FPN) [33]. Se entrena durante 12 épocas siguiendo el programa estándar 1x de MMDetection con optimizador AdamW con learning rate de 0.0001 y weight decay de 0.0001, batch size de 8 y resolución de entrada de 960 por 384 píxeles preservando el aspecto. La eva-

luación de validación se ejecuta en cada época utilizando la métrica COCO bbox con early stopping de paciencia 8 y mejora mínima 0.005, y se selecciona el checkpoint con mayor mAP bbox. Esta configuración de entrenamiento relativamente conservadora con learning rate bajo busca explotar las capacidades de refinamiento multietapa de la arquitectura sin riesgo de divergencia [33].

YOLO26 representa al paradigma de una etapa. Posee una arquitectura convolucional libre de anclajes con diseño de cabeza dual que elimina la etapa NMS [34]. Se configura con la variante yolo26m, resolución de entrenamiento rectangular de 960 por 384 píxeles, batch size de 16 y learning rate inicial de 0.01. El entrenamiento ejecuta el presupuesto completo de 50 épocas con early stopping de paciencia 50 (efectivamente desactivado; las mejores épocas caen entre 40 y 50) y guarda checkpoints cada 5 épocas.

RF-DETR representa al paradigma basado en transformers. Posee una arquitectura con búsqueda de arquitectura neuronal [35]. Se utiliza la variante rfdetr-m con lienzo de entrenamiento rectangular que preserva el aspecto ancho del tablón, batch size de 8, learning rate de 0.0001 y weight decay de  $1e-4$ . El entrenamiento incluye warmup de 5 épocas, early stopping con paciencia de 15 y mejora mínima de 0.005 según la guía oficial, y gradient checkpointing para reducir el consumo de memoria. El número máximo de épocas es 50; el early stopping detiene el entrenamiento entre las épocas 21 y 23 en la práctica, con mejores épocas de validación entre 6 y 11.

Los presupuestos de épocas por paradigma son intencionales y no arbitrarios. Cascade R-CNN sigue el programa estándar 1x de 12 épocas de MMDetection [33], [62], YOLO26 ejecuta el presupuesto completo de 50 épocas de los valores por defecto de Ultralytics [34], y RF-DETR sigue la guía oficial de hasta 50 épocas con early stopping [35]. Los tiempos de cómputo resultan comparables entre paradigmas (0.38 a 0.80 horas por configuración, ver Figura 17) porque el costo

Tabla 2: Hiperparámetros de entrenamiento por paradigma. Cada configuración sigue los valores de referencia de su framework; los valores de mAP son estimaciones puntuales de una sola corrida y la incertidumbre por clase se reporta con intervalos de Wilson simultáneos (ver 4.).

| Modelo                             | Entrada / Batch              | Optimización                                             | Presupuesto                                        |
|------------------------------------|------------------------------|----------------------------------------------------------|----------------------------------------------------|
| Cascade R-CNN (ResNet-50 + FPN)    | 960×384 keep-ratio batch 8   | AdamW, lr 1e-4, wd 1e-4; LinearLR warmup + MultiStepLR   | 12 épocas (1x) paciencia 8, min-delta 0.005        |
| YOLO26m (anchor-free, cabeza dual) | 960×384 rect batch 16        | lr0 0.01 (optimizador por defecto Ultralytics); AMP FP16 | 50 épocas paciencia 50 (efectivamente desactivada) |
| RF-DETR-m (transformer NAS)        | lienzo rect. 960×384 batch 8 | lr 1e-4, wd 1e-4; warmup 5; grad. checkpointing          | máx. 50 (real 21–23) paciencia 15, min-delta 0.005 |

por época difiere, de modo que los conteos de épocas no son directamente comparables. Los tres paradigmas comparten el mismo lienzo rectangular de 960 por 384 que preserva el aspecto ancho del tablón, por lo que el manejo del tamaño de entrada no puede favorecer a ningún paradigma. La Tabla 2 resume los hiperparámetros de entrenamiento; cada elección sigue la configuración de referencia de su framework y no un ajuste ad hoc, manteniendo la comparación atribuible a los efectos de paradigma y aumento.

Los umbrales de confianza se calibran por modelo en lugar de fijarse globalmente. Una pasada de inferencia sobre la partición de validación a 0.05 seguida de un barrido de F1 máximo fija el punto operativo: 0.20 para RF-DETR (F1 0.695) y 0.30 para YOLO26 (F1 0.748), mientras que Cascade R-CNN se mantiene en 0.50. La inferencia de prueba y las métricas de todas las configuraciones de RF-DETR y YOLO26 se ejecutan en estos umbrales. La calibración es necesaria porque el entrenamiento rectangular reduce los puntajes de salida de RF-DETR preservando la calidad del ranking: los mismos checkpoints puntúan mucho más bajo con un corte fijo de 0.50 por pérdida de recall, no por peor localización. Precisión, recall y F1 se reportan por tanto en el punto operativo propio de cada modelo, mientras que las columnas de mAP mantienen la comparación basada en ranking.

#### 4. Resultados

La Figura 4 presenta la matriz de rendimiento mAP@0.5 para las 12 combinaciones de modelo y estrategia de aumento. RF-DETR lidera los cuatro brazos con valores entre 0.676 y 0.717, seguido por Cascade R-CNN entre 0.644 y 0.677, mientras que YOLO26 es el grupo más compacto entre 0.592 y 0.618 con su baseline sin aumento en la cima. La vista de la métrica estricta en la Figura 5 preserva el orden (RF-DETR 0.405 a 0.425, Cascade 0.380 a 0.401, YOLO 0.349 a 0.363). La sensibilidad al aumento es específica de cada paradigma en lugar de uniforme: beneficia a Cascade, es mixta para RF-DETR y es neutra a negativa para YOLO26.

La Tabla 3 resume las métricas completas de las 12 configuraciones. RF-DETR con Albumen-tations alcanza el mayor mAP@0.5 de 0.717 y el mejor mAP@0.5:0.95 de 0.425, mientras que Cascade R-CNN con BoxAug LibCom alcanza la mayor precisión de 0.811 y el mejor F1 de 0.798. YOLO26 baseline es el más fuerte de su familia con mAP@0.5 de 0.618, con las tres estrategias de aumento puntuando de 0.592 a 0.604. Estos resultados sitúan al paradigma transformer primero en métricas de ranking y al paradigma de dos etapas primero en precisión de punto operativo, mientras que el paradigma de una etapa no muestra ganancias impulsadas por aumento bajo este protocolo.




Figura 4: Matriz de rendimiento mAP@0.5 intersectando tres paradigmas de detección con cuatro estrategias de aumento.




Figura 5: Matriz de rendimiento mAP@0.5:0.95 para las mismas 12 configuraciones.

Tabla 3: Métricas de rendimiento en el conjunto de prueba para las 12 configuraciones del benchmark.

| Modelo        | Augmentación   | mAP@50 | mAP@50:95 | Precisión | Recall | F1    |
|---------------|----------------|--------|-----------|-----------|--------|-------|
| Cascade R-CNN | Albumentations | 0.652  | 0.380     | 0.789     | 0.785  | 0.787 |
| Cascade R-CNN | Baseline       | 0.644  | 0.386     | 0.797     | 0.765  | 0.780 |
| Cascade R-CNN | BoxAug Lib-Com | 0.677  | 0.401     | 0.811     | 0.785  | 0.798 |
| Cascade R-CNN | BoxAug Std     | 0.659  | 0.389     | 0.796     | 0.773  | 0.784 |
| RF-DETR       | Albumentations | 0.717  | 0.425     | 0.684     | 0.782  | 0.730 |
| RF-DETR       | Baseline       | 0.700  | 0.420     | 0.667     | 0.794  | 0.725 |
| RF-DETR       | BoxAug Lib-Com | 0.686  | 0.406     | 0.665     | 0.796  | 0.725 |
| RF-DETR       | BoxAug Std     | 0.676  | 0.405     | 0.660     | 0.794  | 0.721 |
| YOLO26        | Albumentations | 0.598  | 0.355     | 0.742     | 0.748  | 0.745 |
| YOLO26        | Baseline       | 0.618  | 0.363     | 0.769     | 0.738  | 0.753 |
| YOLO26        | BoxAug Lib-Com | 0.592  | 0.349     | 0.760     | 0.740  | 0.750 |
| YOLO26        | BoxAug Std     | 0.604  | 0.358     | 0.754     | 0.765  | 0.759 |

La Figura 7 muestra el impacto de cada estrategia de aumento respecto al baseline para cada modelo. Cascade R-CNN se beneficia de cada estrategia: Albumentations aporta +0.008,




Figura 6: Panorama de mAP@0.5 y mAP@0.5:0.95 por configuración modelo-aumento, confirmando el orden RF-DETR, Cascade R-CNN, YOLO26 en ambas métricas.




Figura 7: Impacto de las estrategias de augmentación respecto al baseline ( $\Delta$  mAP@0.5).

BoxAug estándar +0.015 y BoxAug LibCom +0.033 de mejora absoluta en mAP@0.5. RF-DETR muestra un comportamiento mixto: Albumentations aporta +0.017, pero BoxAug estándar degrada el rendimiento en  $-0.024$  y BoxAug LibCom en  $-0.013$ . YOLO26 no muestra ganancia: Albumentations puntúa  $-0.019$ , BoxAug LibCom  $-0.026$  y BoxAug estándar  $-0.014$ , con el baseline sin aumento manteniéndose como su mejor configuración.

La Figura 8 presenta el AP promedio por clase en AP@0.5 para las 12 configuraciones (la Figura 9 muestra los mismos valores en barras). La clase más fácil es médula, con AP de hasta 0.910 con RF-DETR, mientras que cuarcita es la más difícil, con AP entre 0.082 y 0.550. Ninguna configuración falla completamente en ninguna clase. Los nudos vivos y nudos muertos muestran valores de AP de 0.651 a 0.781 a pesar de ser las clases mayoritarias, lo que sugiere alta varianza intraclase.

La Figura 10 presenta el mismo desglose por clase bajo la métrica AP@0.5:0.95. El orden de clases se preserva: médula sigue siendo la clase más fácil de 0.499 a 0.639 y cuarcita la más difícil de 0.064 a 0.285. La métrica comprime el rango de puntajes, más visiblemente en las clases mayoritarias, pues los nudos vivos y muertos caen de 0.651–0.781 en AP@0.5 a 0.297–0.449,

indicando que estos defectos de alta varianza se detectan pero se localizan mal. La celda más débil es YOLO26 con BoxAug LibCom en cuarcita con 0.064, frente a 0.255 de su baseline sin aumento, mostrando que el aumento pegado degrada la localización de clases raras en el paradigma de una etapa. RF-DETR lidera seis de ocho clases bajo la métrica, con sus mejores celdas en médula con 0.639 (BoxAug Std) y Knot\_missing con 0.502 (Albumentations).

La Tabla 4 y la Figura 11 reportan el recall por clase con IC simultáneos del 95% para la mejor configuración de cada paradigma. Las clases abundantes dan intervalos estrechos (Live\_Knot,  $n = 395$ : recall 0.729–0.792 con anchos 0.111–0.122), mientras que las clases raras abarcan decenas de puntos (cuarcita,  $n = 15$ : 0.400–0.733 con anchos 0.533–0.576; Knot\_missing,  $n = 12$ : anchos de hasta 0.614), por lo que los órdenes entre clases raras no son estadísticamente distinguibles: la brecha en cuarcita entre RF-DETR (0.733) y YOLO26 (0.400) se solapa en los tres intervalos. La precisión muestra el mismo patrón, con Cascade R-CNN manteniendo los intervalos más estrechos en clases mayoritarias (Live\_Knot 0.853 [0.795, 0.896], Dead\_Knot 0.905 [0.841, 0.945]) mientras que la precisión de RF-DETR en cuarcita abarca 0.133–0.501.




Figura 8: Mapa de calor de precisión promedio por clase de defecto (AP@0.5).

La Figura 12 muestra instancias representativas anotadas con ground truth (cajas rojas) para las ocho clases de defectos junto con el mejor AP@0.5 entre las 12 configuraciones. El panel visualiza el espectro de dificultad detrás de los números: el distintivo patrón de línea central de la médula (0.91) contrasta con el bajo contraste de la cuarcita contra la veta de la madera (0.55, clase más difícil), mientras que las instancias de nudos faltantes se concentran en los bordes del tablón donde los intervalos de recall de punto operativo son más amplios ( $n = 12$ , anchos de hasta 0.614). Los modos de fallo característicos se derivan de los conteos de punto operativo: los falsos positivos de cuarcita surgen de la confusión con la veta (la precisión de RF-DETR en cuarcita abarca 0.133–0.501), y las confusiones entre nudos aparecen como falsos positivos y falsos negativos pareados en lugar de entradas fuera de la diagonal (ver 3.4.).

La Figura 13 ilustra el compromiso entre velocidad de inferencia y precisión. YOLO26 procesa cada imagen en 7.5 ms en promedio de

las cuatro configuraciones, RF-DETR en 12.6 ms y Cascade R-CNN en 25.7 ms. Cascade R-CNN es 3.4 veces más lento que YOLO26 mientras que su mejor mAP@0.5 de 0.677 está por debajo del mejor de RF-DETR de 0.717. RF-DETR ofrece la mejor precisión de ranking con 12.6 ms, 1.7 veces más lento que YOLO26, cuyo mejor mAP@0.5 es 0.618. La Figura 14 detalla la precisión, recall y F1 de punto operativo detrás de estos compromisos.

La Figura 15 muestra las curvas de convergencia de mAP@0.5 en validación a lo largo de las épocas (la Figura 16 muestra las pérdidas de entrenamiento correspondientes). RF-DETR converge más temprano, con mejor época entre 6 y 11, Cascade R-CNN se estabiliza entre la época 9 y 12 con BoxAug LibCom aún en ascenso en la época 12, y YOLO26 alcanza su máximo entre las épocas 40 y 50, al borde de su presupuesto de 50 épocas. Las curvas de YOLO26 presentan mayor oscilación, particularmente en la configuración BoxAug estándar. Este patrón de convergencia sugiere que los transformers necesitan




Figura 9: Barras de precisión promedio por clase (AP@0.5) para las 12 configuraciones.

menos iteraciones para capturar las características relevantes, mientras que las arquitecturas convolucionales de una etapa consumen el presupuesto completo; las curvas aún ascendentes de YOLO26 y Cascade LibCom indican que ambos presupuestos truncan el aprendizaje. La oscilación en YOLO26 puede indicar sensibilidad a la variabilidad de las muestras de entrenamiento en cada lote.

La Figura 17 compara el tiempo total de entrenamiento por configuración. YOLO26 entrena las 50 épocas completas en 0.40 a 0.80 horas, Cascade R-CNN completa 12 épocas en 0.38 a 0.78 horas, y RF-DETR entrena 21 a 23 épocas en 0.44 a 0.80 horas. Los presupuestos de tiempo de cómputo son por tanto comparables entre paradigmas aunque los conteos de épocas difieran, y el costo por época más que el early stopping domina las diferencias.

## 5. Discusión

Los resultados obtenidos en este benchmark revelan patrones que ameritan un análisis detallado sobre las interacciones entre arquitecturas de detección y estrategias de aumento de datos en el contexto del desequilibrio severo de clases propio de la inspección industrial de madera. El liderazgo de RF-DETR en precisión de ranking, con mAP@0.5 de 0.717, está condicionado a dos decisiones declaradas del protocolo: umbrales calibrados por modelo y un presupuesto de 21 a 23 épocas frente a las 12 fijas de Cascade. Su autoatención global bidireccional captura dependencias espaciales de largo alcance sobre la superficie del tablón [56], pero el margen sobre el mejor brazo de Cascade (+0.040) no puede leerse como un efecto puro de arquitectura mientras los presupuestos de entrenamiento difieran en un factor de dos. Cascade R-CNN mantiene el




Figura 10: Mapa de calor de precisión promedio por clase de defecto (AP@0.5:0.95).

liderazgo en precisión de punto operativo, con precisión de 0.811 y F1 de 0.798 bajo BoxAug LibCom, consistente con el refinamiento en cascada que minimiza falsos positivos mediante cabezales de detección con umbrales crecientes de Intersección sobre Unión [33]. Notablemente, Cascade es el único paradigma que se beneficia de cada estrategia de aumento (+0.008 a +0.033), sugiriendo que los cabezales de dos

etapas explotan las instancias sintéticas minoritarias una vez fijado el punto operativo.

YOLO26 no muestra dividendo del aumento: el baseline sin aumento con mAP@0.5 de 0.618 supera a los tres brazos aumentados, que puntúan de 0.592 a 0.604. Esto contradice la expectativa común de que los detectores de una etapa son los principales beneficiarios del volumen de datos de entrenamiento [31], al menos bajo

Tabla 4: Recall por clase con IC simultáneos del 95% a nivel familiar (Bonferroni) para la mejor configuración de cada paradigma, con soporte  $n$  de prueba.

| Clase           | RF-DETR (Alb.)       | Cascade (LibCom)     | YOLO26 (Base.)       | $n$ |
|-----------------|----------------------|----------------------|----------------------|-----|
| Quartzity       | 0.733 [0.389, 0.922] | 0.467 [0.190, 0.766] | 0.400 [0.149, 0.718] | 15  |
| Live_Knot       | 0.754 [0.691, 0.809] | 0.792 [0.731, 0.843] | 0.729 [0.664, 0.786] | 395 |
| Marrow          | 0.857 [0.561, 0.966] | 0.857 [0.561, 0.966] | 0.905 [0.614, 0.983] | 21  |
| resin           | 0.891 [0.741, 0.959] | 0.813 [0.649, 0.910] | 0.703 [0.533, 0.831] | 64  |
| Dead_Knot       | 0.767 [0.692, 0.828] | 0.763 [0.688, 0.825] | 0.788 [0.715, 0.846] | 287 |
| knot_with_crack | 0.787 [0.591, 0.905] | 0.766 [0.568, 0.891] | 0.702 [0.503, 0.846] | 47  |
| Knot_missing    | 0.833 [0.441, 0.969] | 0.750 [0.369, 0.939] | 0.417 [0.142, 0.756] | 12  |
| Crack           | 0.922 [0.758, 0.978] | 0.902 [0.733, 0.969] | 0.706 [0.515, 0.845] | 51  |




Figura 11: Recall por clase con intervalos de confianza simultáneos del 95% a nivel familiar para la mejor configuración de cada paradigma. Las barras de error son intervalos de Wilson al 99.375% por clase, es decir cobertura simultánea del 95% a nivel familiar sobre las 8 clases (Bonferroni).

entrenamiento rectangular con un presupuesto completo de 50 épocas. Un mecanismo plausible es que las predicciones densas libres de anclajes de YOLO26 ya se saturan en la distribución mayoritaria, de modo que las instancias minoritarias pegadas añaden ruido más que señal con este presupuesto. Cuarcita alcanza  $AP@0.5$  de 0.346 con el baseline de YOLO26, de modo que ninguna clase se pierde por completo. La mayor oscilación observada en las curvas de convergencia de YOLO26, particularmente en la configuración BoxAug estándar, puede atribuirse a la variabilidad introducida por las muestras sintéticas en un modelo que carece del mecanismo de refinamiento multietapa de Cascade R-CNN.

Este resultado sugiere que las técnicas de aumento por objeto requieren presupuestos mayores o síntesis más limpia para ayudar a detectores de una etapa en escenarios de desequilibrio severo.

RF-DETR muestra un comportamiento mixto: Albumentations mejora el rendimiento en  $+0.017$ , pero BoxAug estándar lo degrada en  $-0.024$  y BoxAug LibCom en  $-0.013$ . Este resultado es particularmente relevante para la comunidad de investigación en transformers para visión industrial [32]. Las transformaciones de ruido a nivel de parche introducen artefactos que los mecanismos de autoatención global bidireccional interpretan como patrones relevantes,




Figura 12: Instancias representativas anotadas con ground truth (cajas rojas) con el mejor  $AP@0.5$  por clase. Cuarcita es la clase más difícil y médula la más fácil; los nudos faltantes son propensos a bordes con los intervalos de recall más amplios.




Figura 13: Compromiso entre velocidad de inferencia (ms/imagen) y precisión (mAP@0.5).

generando confusión durante el entrenamiento. A diferencia de los modelos convolucionales, que procesan información local mediante filtros deslizantes, los transformers capturan dependencias




Figura 14: Precisión, recall y F1 en el punto operativo por configuración en el umbral calibrado de cada modelo.




Figura 15: Curvas de convergencia de mAP@0.5 en validación durante el entrenamiento.

espaciales de largo alcance que pueden amplificar la influencia de artefactos locales [56]. El mecanismo es estructural. BoxAug estándar pega parches con ruido a nivel de píxel y perturbaciones morfológicas [36], produciendo gradientes de borde abruptos y texturas de alta frecuencia que no ocurren en la veta natural de la

madera. Durante la tokenización estas discontinuidades se convierten en tokens atípicos; dado que cada cabezal de autoatención computa afinidades Query-Key sobre el conjunto completo de tokens, un solo parche anómalo puede atraer masa de atención desde regiones distantes libres de defectos y propagar correlaciones espurias a



Figura 16: Progresión de la pérdida de entrenamiento por época para las 12 configuraciones.




Figura 17: Comparación del tiempo total de entrenamiento por configuración.

través de las capas. Los detectores convolucionales atenúan este efecto mediante localidad: los filtros deslizantes confinan el campo receptivo del artefacto y los cabezales IoU por etapas de Cascade R-CNN aún pueden rechazar la propuesta. Los transformers carecen de ese cuello de botella de localidad, de modo que el mismo artefacto se difunde globalmente. La armonización neuronal vía LibCom [38] atenúa los gradientes de borde mediante igualación de color a nivel de píxel [39], lo que explica por qué BoxAug LibCom degrada RF-DETR menos ( $-0.013$ ) que la variante estándar ( $-0.024$ ): los tokens pegados permanecen distribucionalmente más cercanos a la veta natural. El fenómeno de puntajes reducidos, donde los mismos checkpoints colapsan con un corte fijo de 0.50 mientras la calidad del ranking se preserva, muestra además que la evaluación de umbral-luego-mAP es frágil ante cambios de calibración. Este resultado sugiere que las estrategias de aumento por objeto requieren una adaptación cuidadosa cuando se aplican a arquitecturas basadas en autoatención, y que los puntos operativos deben ajustarse por modelo en lugar de fijarse globalmente.

El análisis por clase revela resultados contraintuitivos que desafían la suposición de que la

frecuencia de clase determina directamente la dificultad de detección. Cuarcita, con solo 144 anotaciones (1.6% del dataset), obtiene el peor rendimiento con  $AP@0.5$  entre 0.082 y 0.550, lo cual es esperable dado su bajo contraste visual contra la veta de la madera. Sin embargo, médula, con solo 204 anotaciones, obtiene el mayor AP de hasta 0.910. Esta disparidad indica que la distinguibilidad visual del defecto es un factor determinante que interactúa con la frecuencia de clase. Los defectos con patrones visuales distintivos, como la médula con su apariencia característica de línea central, son más susceptibles a la detección automática independientemente de su representación en el dataset [5].

Los nudos vivos y nudos muertos, que representan conjuntamente alrededor del 77% del dataset, muestran valores de  $AP@0.5$  de 0.651 a 0.781 a pesar de su alta prevalencia. Este hallazgo confirma que la alta varianza intraclase de estos defectos, donde un mismo tipo de anomalía puede presentar apariencias visuales muy diferentes [9], constituye un desafío que no se resuelve únicamente con mayor volumen de datos. La variabilidad en el grano de la madera de fondo, combinada con las diferentes presentaciones de nudos vivos y muertos, genera

una distribución de características que dificulta la convergencia del modelo hacia representaciones discriminativas robustas. El submuestreo del 35% de tableros mayoritarios en entrenamiento combinado con ponderación por clase de número efectivo [52] mantiene competitivas a las clases minoritarias: la mejor configuración no puntúa ninguna clase por debajo de 0.55. Tratamientos a nivel de pérdida más allá de una única ponderación fija, como Focal Loss [61] o Seesaw Loss [54], permanecen sin evaluar y podrían ofrecer una solución más integral para el desequilibrio severo de clases.

En términos de eficiencia computacional, el compromiso entre velocidad y precisión se manifiesta de manera diferenciada entre los tres paradigmas. YOLO26 ofrece la mejor velocidad con 7.5 ms por imagen y mAP@0.5 de 0.618, lo cual es relevante para líneas de producción de alto rendimiento [9]. Cascade R-CNN es preferido cuando la precisión de punto operativo se prioriza sobre la latencia, alcanzando precisión de 0.811 con 25.7 ms por imagen. RF-DETR ofrece la mejor precisión de ranking con 12.6 ms y mAP@0.5 de 0.717, posicionándose como una alternativa viable para aplicaciones donde el compromiso velocidad-precisión debe balancearse con la capacidad de capturar dependencias espaciales de largo alcance. La selección de la arquitectura óptima dependerá de los requisitos específicos de la aplicación industrial, considerando factores como la velocidad de la línea de producción, la tolerancia a falsos positivos y los recursos computacionales disponibles.

## 6. Conclusiones

Este estudio presentó un benchmark comparativo de tres paradigmas de detección de objetos con cuatro estrategias de aumento de datos para el reconocimiento de defectos superficiales en madera, evaluando 12 configuraciones sobre un dataset con desequilibrio severo de 1 a 35.3. Los resultados principales demuestran que RF-DETR alcanza la mayor precisión de ranking con mAP@0.5 de 0.717 bajo umbrales calibrados por modelo, Cascade R-CNN gana más con el au-

mento con BoxAug LibCom aportando +0.033 y el mejor F1 de punto operativo de 0.798, y YOLO26 no muestra dividendo del aumento con su baseline sin aumento de 0.618 liderando la familia. El análisis por clase en AP@0.5 revela que la dificultad de detección depende tanto de la frecuencia como de la distinguibilidad visual del defecto. Los cortes fijos de confianza miden mal a los modelos entrenados en rectangular, de modo que la calibración del punto operativo es parte del método más que un detalle posterior.

Para el despliegue, los tres paradigmas ocupan distintos puntos operativos: YOLO26 con 7.5 ms por imagen se ajusta a líneas de alto rendimiento cercanas a 9.6 m/s donde la latencia domina; RF-DETR con 12.6 ms ofrece la mejor precisión de ranking para requisitos balanceados de velocidad y precisión; y Cascade R-CNN con 25.7 ms maximiza la precisión de punto operativo (0.811) donde los falsos positivos son costosos. Estas afirmaciones están acotadas por los límites del estudio: estimaciones puntuales de mAP de una sola corrida sin varianza de entrenamiento, presupuestos de épocas truncados que convierten los puntajes de YOLO26 y Cascade LibCom en cotas inferiores más que en valores convergidos, y evaluación en una sola especie y entorno industrial. El protocolo de umbrales calibrados, la respuesta al aumento dependiente del paradigma y el pipeline reproducible publicado proporcionan la línea base contra la cual deberán medirse presupuestos extendidos, corridas repetidas con intervalos de confianza y aumento basado en difusión.

## 7. Limitaciones y Trabajos Futuros

Los presupuestos fijos de épocas por familia truncan el aprendizaje donde las curvas aún ascienden: las mejores épocas de YOLO26 caen entre 40 y 50 de un presupuesto de 50 épocas, y Cascade R-CNN con BoxAug LibCom aún está en ascenso en la época 12 de 12, de modo que los puntajes reportados son cotas inferiores para esas configuraciones más que valores convergidos. Extender YOLO26 más allá de 50 épocas y Cascade R-CNN a su programa 2x probaría si

el ranking se mantiene en convergencia. Todos los valores de mAP reportados son estimaciones puntuales de una sola corrida; un protocolo de repetición de tres semillas (semillas 42–44, media  $\pm$  std) es el siguiente paso natural para intervalos de varianza de entrenamiento alrededor del mAP. La dirección de modelado más inmediata corresponde al aumento basado en difusión. Los métodos de cut-and-paste evaluados, como Bo-xAug, están limitados por la cantidad de instancias raras disponibles para recortar del dataset original. Con solo 144 anotaciones de cuarcita, el banco de objetos es demasiado pequeño para generar aumento diverso. Los modelos de difusión condicional como Stable Diffusion con ControlNet pueden generar instancias sintéticas de clases raras sin depender de recortes existentes, ofreciendo una alternativa potencialmente más efectiva para desbalance severo [55].

Los mapas de calor de AP por clase anteriores siguen siendo estimaciones puntuales (la construcción binomial-Bonferroni no aplica a AP, una métrica de ranking), y la confusión entre clases se pliega en falsos positivos y falsos negativos por clase en lugar de mostrarse como matriz fuera de la diagonal.

La expansión del dataset hacia otras especies de madera con diferentes patrones de grano y defectos es esencial para validar la generalización más allá de la especie y entorno industrial actuales. En paralelo, la cuantización de modelos a INT8 y FP16 podría reducir tiempos de inferencia para el despliegue en líneas de producción con restricciones de hardware, mientras que la evaluación de arquitecturas transformer como DINO y Grounding DINO podría determinar si los mecanismos de autoatención global mejoran la detección de defectos de bajo contraste. La combinación de múltiples líneas de investigación, incluyendo ponderación por clase, augmentación basada en difusión y optimización de modelos, podría conducir a sistemas de inspección más robustos y eficientes para la industria maderera. Estas direcciones futuras buscan abordar las limitaciones identificadas en el presente benchmark y acercar los sistemas de detección

automatizada a los requisitos operativos de las plantas de procesamiento de madera. El desarrollo de pipelines experimentales reproducibles, como el empleado en este estudio, facilitará la evaluación comparativa de las nuevas técnicas que surjan de estas líneas de investigación.

## Declaración de Contribución de Autoría CRediT

**Ricardo Mauricio Chambilla Perca:** Software, Redacción – borrador original. **Mariel Alison Jara Mamani:** Curaduría de datos, Recursos, Metodología. **Christian Raul Mestas Zegarra:** Administración del proyecto, Conceptualización, Redacción – revisión y edición. **Yenaro Joel Noa Camino:** Investigación, Recursos. **Luis Gustavo Sequeiros Condonari:** Conceptualización, Investigación, Software. **Yasiel Pérez Vera:** Supervisión, Redacción – revisión y edición.

## Declaración de Conflictos de Intereses

Los autores declaran que no tienen ningún conflicto de intereses económicos conocido ni relaciones personales que pudieran dar la impresión de influir en el trabajo presentado en este artículo.

## Financiamiento

Esta investigación no recibió ninguna subvención específica de organismos financiadores de los sectores público, comercial o sin fines de lucro.

## Disponibilidad de Código

Los scripts de análisis personalizados y código fuente generados durante este estudio están públicamente disponibles en el repositorio de GitHub: <https://github.com/christianmz565/ia-2026-final>, licenciado bajo la licencia AGPL-3.0.

## Disponibilidad de Datos

Los datos utilizados en este estudio están disponibles públicamente en Kaggle: <https://www.kaggle.com/datasets/nomihsa>

## Referencias

- [1] J. Yang, S. Li, Z. Wang, H. Dong, J. Wang, y S. Tang, «Using Deep Learning to Detect Defects in Manufacturing: A Comprehensive Survey and Current Challenges», *Materials*, vol. 13, p. 5755, 2020, doi: [10.3390/ma13245755](https://doi.org/10.3390/ma13245755).
- [2] T. Czimmermann *et al.*, «Visual-Based Defect Detection and Classification Approaches for Industrial Applications—A SURVEY», *Sensors*, vol. 20, n.º 5, p. 1459, 2020, doi: [10.3390/s20051459](https://doi.org/10.3390/s20051459).
- [3] M. Ramos-Maldonado y E. Aguilera-Carrasco, «Trends and Opportunities of Industry 4.0 in Wood Manufacturing Processes», en *Sustainable Wood and Biomass from Residual Forests and Collections*, IntechOpen, 2021. doi: [10.5772/intechopen.99581](https://doi.org/10.5772/intechopen.99581).
- [4] Q. Yin y H.-H. Liu, «Drying Stress and Strain of Wood: A Review», *Applied Sciences*, vol. 11, n.º 11, pp. 5023-5041, 2021, doi: [10.3390/app11115023](https://doi.org/10.3390/app11115023).
- [5] Y. Chen, C. Sun, Z. Ren, y B. Na, «Wood defect recognition: Review of the current state of application of wood defect recognition technology», *BioResources*, vol. 18, n.º 1, pp. 2288-2302, 2023, doi: [10.15376/biores.18.1.Chen](https://doi.org/10.15376/biores.18.1.Chen).
- [6] M. Kryl, L. Danys, R. Jaros, R. Martinek, P. Kodytek, y P. Bilik, «Wood Recognition and Quality Imaging Inspection Systems», *Sensors*, vol. 2020, p. 3217126, 2020, doi: [10.1155/2020/3217126](https://doi.org/10.1155/2020/3217126).
- [7] M. Ericsson, D. Johansson, y D. Stjern, «AI-Based Quality Control of Wood Surfaces with Autonomous Material Handling», *Applied Sciences*, vol. 11, n.º 21, pp. 9965-9978, 2021, doi: [10.3390/app11219965](https://doi.org/10.3390/app11219965).
- [8] H. Shah, E. Saarela, T. Korkeakangas, y T. Pitkääho, «A Comprehensive Review of Automatic Defect Detection in Wood Surface Inspection», *Applied Computing and Intelligence*, vol. 6, n.º 1, pp. 1-22, 2026, doi: [10.3934/aci.2026001](https://doi.org/10.3934/aci.2026001).
- [9] P. Kodytek, A. Bodzaš, y P. Bilik, «A Large-Scale Image Dataset of Wood Surface Defects for Automated Vision-Based Quality Control Processes», *F1000Research*, vol. 10, p. 581, 2022, doi: [10.12688/f1000research.52903.2](https://doi.org/10.12688/f1000research.52903.2).
- [10] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, y D. Terzopoulos, «A Survey on Object Instance Segmentation: A Deep Learning Survey», *SN Computer Science*, vol. 3, n.º 6, p. 407, 2022, doi: [10.1007/s42979-022-01407-3](https://doi.org/10.1007/s42979-022-01407-3).
- [11] M. Prunella *et al.*, «Deep Learning for Automatic Vision-Based Recognition of Industrial Surface Defects: A Survey», *IEEE Access*, vol. 11, pp. 42605-42630, 2023, doi: [10.1109/access.2023.3271748](https://doi.org/10.1109/access.2023.3271748).
- [12] Z. Ren, F. Fang, N. Yan, y Y. Wu, «State of the Art in Defect Detection Based on Machine Vision», *International Journal of Precision Engineering and Manufacturing-Green Technology*, vol. 9, pp. 661-691, 2022, doi: [10.1007/s40684-021-00343-6](https://doi.org/10.1007/s40684-021-00343-6).
- [13] N. Dalal y B. Triggs, «Histograms of Oriented Gradients for Human Detection», en *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, 2005, pp. 886-893. doi: [10.1109/CVPR.2005.177](https://doi.org/10.1109/CVPR.2005.177).
- [14] B. Sugiarto *et al.*, «Wood identification based on histogram of oriented gradient (HOG) feature and support vector machine (SVM) classifier», en *2017 2nd International Conferences on Infor-*

- mation Technology, Information Systems and Electrical Engineering (ICITISEE), 2017, pp. 337-341. doi: [10.1109/ICITISEE.2017.8285523](https://doi.org/10.1109/ICITISEE.2017.8285523).
- [15] Z. Nurthohari, M. A. Murti, y C. Setianingsih, «Wood Quality Classification Based on Texture and Fiber Pattern Recognition using HOG Feature and SVM Classifier», en *2019 IEEE International Conference on Internet of Things and Intelligence System (IoTaIS)*, 2019, pp. 123-128. doi: [10.1109/IoTaIS47347.2019.8980414](https://doi.org/10.1109/IoTaIS47347.2019.8980414).
- [16] P. Viola y M. Jones, «Rapid Object Detection using a Boosted Cascade of Simple Features», en *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, 2001, p. I-511. doi: [10.1109/CVPR.2001.990517](https://doi.org/10.1109/CVPR.2001.990517).
- [17] R. Lienhart y J. Maydt, «An Extended Set of Haar-like Features for Rapid Object Detection», en *Proceedings of the International Conference on Image Processing (ICIP)*, 2002, p. I-900. doi: [10.1109/ICIP.2002.1038171](https://doi.org/10.1109/ICIP.2002.1038171).
- [18] A. Ranftl, F. Alonso-Fernandez, S. Karlsson, y J. Bigun, «Real-time AdaBoost Cascade Tracking with Likelihood Maps», *arXiv preprint arXiv:2210.13885*, 2022, doi: [10.48550/arXiv.2210.13885](https://doi.org/10.48550/arXiv.2210.13885).
- [19] J. Ma, X. Jiang, A. Fan, J. Jiang, y J. Yan, «Image Matching from Hand-crafted to Deep Features: A Survey», *International Journal of Computer Vision*, vol. 129, pp. 23-79, 2021, doi: [10.1007/s11263-020-01359-2](https://doi.org/10.1007/s11263-020-01359-2).
- [20] L. Alzubaidi *et al.*, «Review of deep learning: concepts, CNN architectures, challenges, applications, future directions», *Journal of Big Data*, vol. 8, n.º 1, p. 53, 2021, doi: [10.1186/s40537-021-00444-8](https://doi.org/10.1186/s40537-021-00444-8).
- [21] L. Jiao *et al.*, «A Survey of Deep Learning-Based Object Detection», *IEEE Access*, vol. 7, pp. 128837-128868, 2019, doi: [10.1109/access.2019.2939201](https://doi.org/10.1109/access.2019.2939201).
- [22] S. Ren, K. He, R. Girshick, y J. Sun, «Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks», *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, n.º 6, pp. 1137-1149, 2017, doi: [10.1109/tpami.2016.2577031](https://doi.org/10.1109/tpami.2016.2577031).
- [23] K. He, G. Gkioxari, P. Dollár, y R. Girshick, «Mask R-CNN», en *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2961-2969. doi: [10.1109/ICCV.2017.322](https://doi.org/10.1109/ICCV.2017.322).
- [24] W. Liu *et al.*, «SSD: Single Shot MultiBox Detector», *arXiv preprint arXiv:1512.02325*, 2016, doi: [10.48550/arXiv.1512.02325](https://doi.org/10.48550/arXiv.1512.02325).
- [25] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan, y S. Belongie, «Feature Pyramid Networks for Object Detection», en *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2117-2125. doi: [10.1109/cvpr.2017.106](https://doi.org/10.1109/cvpr.2017.106).
- [26] Z. Tian, C. Shen, H. Chen, y T. He, «FCOS: Fully Convolutional One-Stage Object Detection», en *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 9627-9636. doi: [10.1109/iccv.2019.00972](https://doi.org/10.1109/iccv.2019.00972).
- [27] J. Redmon, S. Divvala, R. Girshick, y A. Farhadi, «You Only Look Once: Unified, Real-Time Object Detection», en *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779-788. doi: [10.1109/cvpr.2016.91](https://doi.org/10.1109/cvpr.2016.91).
- [28] J. Redmon y A. Farhadi, «YOLO9000: Better, Faster, Stronger», en *Proceedings of*

- the *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 7263-7271. doi: [10.1109/cvpr.2017.690](https://doi.org/10.1109/cvpr.2017.690).
- [29] J. Redmon y A. Farhadi, «YOLOv3: An Incremental Improvement», *arXiv preprint arXiv:1804.02767*, 2018, doi: [10.48550/arxiv.1804.02767](https://doi.org/10.48550/arxiv.1804.02767).
- [30] A. Bochkovskiy, C.-Y. Wang, y H.-Y. M. Liao, «YOLOv4: Optimal Speed and Accuracy of Object Detection», *arXiv preprint arXiv:2004.10934*, 2020, doi: [10.48550/arxiv.2004.10934](https://doi.org/10.48550/arxiv.2004.10934).
- [31] M. Hussain, «YOLO-v1 to YOLO-v8, the Rise of YOLO and Its Complementary Nature toward Digital Manufacturing and Industrial Defect Detection», *Machines*, vol. 11, n.º 7, p. 677, 2023, doi: [10.3390/machines11070677](https://doi.org/10.3390/machines11070677).
- [32] N. Hutten, R. Meyes, y T. Meisen, «Vision Transformer in Industrial Visual Inspection», *Applied Sciences*, vol. 12, n.º 23, p. 11981, 2022, doi: [10.3390/app122311981](https://doi.org/10.3390/app122311981).
- [33] Z. Cai y N. Vasconcelos, «Cascade R-CNN: Delving Into High Quality Object Detection», en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 6154-6162. doi: [10.1109/cvpr.2018.00644](https://doi.org/10.1109/cvpr.2018.00644).
- [34] G. Jocher, J. Qiu, M. Liu, S. Lyu, F. C. Akyon, y M. E. Kalfaoglu, «Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models». [En línea]. Disponible en: <https://arxiv.org/abs/2606.03748>
- [35] I. Robinson, P. Robicheaux, M. Popov, D. Ramanan, y N. Peri, «RF-DETR: Neural Architecture Search for Real-Time Detection Transformers». [En línea]. Disponible en: <https://arxiv.org/abs/2511.09554>
- [36] K. Lee, S. Lee, y H. Y. Kim, «Bounding-box object augmentation with random transformations for automated defect detection in residential building façades», *Automation in Construction*, vol. 135, p. 104138, 2022, doi: [10.1016/j.autcon.2022.104138](https://doi.org/10.1016/j.autcon.2022.104138).
- [37] G. Ghiasi *et al.*, «Simple Copy-Paste is a Strong Data Augmentation Method for Instance Segmentation», en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 2918-2928. [En línea]. Disponible en: <https://arxiv.org/abs/2012.07177>
- [38] L. Niu *et al.*, «Making Images Real Again: A Comprehensive Survey on Deep Image Composition». [En línea]. Disponible en: <https://arxiv.org/abs/2106.14490>
- [39] J. J. A. Guerreiro, M. Nakazawa, y B. Stenger, «PCT-Net: Full Resolution Image Harmonization Using Pixel-Wise Color Transformations», en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, jun. 2023, pp. 5917-5926.
- [40] C. Chadebec, O. Tasar, S. Sreetharan, y B. Aubin, «LBM: Latent Bridge Matching for Fast Image-to-Image Translation». [En línea]. Disponible en: <https://arxiv.org/abs/2503.07535>
- [41] A. Urbonas, V. Raudonis, R. Maskeliūnas, y R. Damaševičius, «Automated Identification of Wood Veneer Surface Defects Using Faster Region-Based Convolutional Neural Network with Data Augmentation and Transfer Learning», *Applied Sciences*, vol. 9, n.º 22, p. 4898, 2019, doi: [10.3390/app9224898](https://doi.org/10.3390/app9224898).
- [42] Y. Fang, X. Guo, y K. Chen, «Accurate and automated detection of surface knots on sawn timbers using YOLO-V5 model», *BioResources*, vol. 16, n.º 3, pp. 5390-5406, 2021, doi: [10.15376/biores.16.3.5390-5406](https://doi.org/10.15376/biores.16.3.5390-5406).
- [43] S. Han, X. Jiang, y Z. Wu, «An Improved YOLOv5 Algorithm for Wood Defect

- Detection Based on Attention», *IEEE Access*, vol. 11, pp. 71554-71565, 2023, doi: [10.1109/access.2023.3293864](https://doi.org/10.1109/access.2023.3293864).
- [44] Y. Zheng, M. Wang, B. Zhang, X. Shi, y Q. Chang, «GBCD-YOLO: A High-Precision and Real-Time Lightweight Model for Wood Defect Detection», *IEEE Access*, vol. 12, pp. 25871-25887, 2024, doi: [10.1109/ACCESS.2024.3356048](https://doi.org/10.1109/ACCESS.2024.3356048).
- [45] K. Zheng, X. Li, y W. Liu, «Wood Defect Detection Based on the CWB-YOLOv8 Algorithm», *Journal of Wood Science*, vol. 70, n.º 1, p. 21, 2024, doi: [10.1186/s10086-024-02139-z](https://doi.org/10.1186/s10086-024-02139-z).
- [46] P. Sun, «Wood Quality Defect Detection Based on Deep Learning and Multicriteria Framework», *Mathematical Problems in Engineering*, vol. 2022, pp. 1-12, 2022, doi: [10.1155/2022/4878090](https://doi.org/10.1155/2022/4878090).
- [47] K. Kılıç, K. Kılıç, İ. A. Doğru, y U. Özcan, «WD Detector: deep learning-based hybrid sensor design for wood defect detection», *European Journal of Wood and Wood Products*, vol. 83, p. 50, 2025, doi: [10.1007/s00107-025-02211-5](https://doi.org/10.1007/s00107-025-02211-5).
- [48] M. Ji, W. Zhang, J.-K. Han, H. Miao, X.-L. Diao, y G.-F. Wang, «A Deep Learning-Based Algorithm for Online Detection of Small Target Defects in Large-Size Sawn Timber», *Industrial Crops and Products*, vol. 225, p. 119671, 2024, doi: [10.1016/j.indcrop.2024.119671](https://doi.org/10.1016/j.indcrop.2024.119671).
- [49] P. Wolszczak, G. Kotnarowski, A. Małek, y G. Litak, «Training of a Neural Network System in the Task of Detecting Blue Stains in a Sawmill Wood Inspection System», *Applied Sciences*, vol. 14, n.º 9, p. 3885, 2024, doi: [10.3390/app14093885](https://doi.org/10.3390/app14093885).
- [50] L.-C. Chen, M. S. Pardeshi, y W.-T. Lo, «Edge-glued wooden panel defect detection using deep learning», *Wood Science and Technology*, vol. 56, pp. 255-276, 2022, doi: [10.1007/s00226-021-01316-3](https://doi.org/10.1007/s00226-021-01316-3).
- [51] Y. Zhang, B. Kang, B. Hooi, S. Yan, y J. Feng, «Deep Long-Tailed Learning: A Survey», *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, n.º 9, pp. 10795-10816, 2023, doi: [10.1109/TPAMI.2023.3268118](https://doi.org/10.1109/TPAMI.2023.3268118).
- [52] Y. Cui, M. Jia, T.-Y. Lin, Y. Song, y S. Belongie, «Class-Balanced Loss Based on Effective Number of Samples», en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019, pp. 9260-9269. doi: [10.1109/CVPR.2019.00949](https://doi.org/10.1109/CVPR.2019.00949).
- [53] J. Tan *et al.*, «Equalization Loss for Long-Tailed Object Recognition», en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 11662-11671. [En línea]. Disponible en: <https://arxiv.org/abs/2003.05176>
- [54] J. Wang *et al.*, «Seesaw Loss for Long-Tailed Instance Segmentation», en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 9695-9704. [En línea]. Disponible en: <https://arxiv.org/abs/2008.10032>
- [55] L. Capogrosso *et al.*, «Diffusion-based Image Generation for In-distribution Data Augmentation in Surface Defect Detection». [En línea]. Disponible en: <https://arxiv.org/abs/2406.00501>
- [56] Y. Zhao *et al.*, «DETRs Beat YOLOs on Real-time Object Detection», en *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2304.08069>
- [57] Nomihisa, *Large-Scale Image Dataset of Wood Surface Defects*. (2024). Kaggle. Accedido: 19 de junio de 2026. [En línea]. Disponible en: <https://www.kaggle.com/>

[datasets/nomihsa965/large-scale-image-dataset-of-wood-surface-defects](#)

- [58] S. Colvin *et al.*, «Pydantic», *Zenodo*, 2024.
- [59] N. Otsu, «A Threshold Selection Method from Gray-Level Histograms», *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 9, n.º 1, pp. 62-66, 1979, doi: [10.1109/TSMC.1979.4310076](#).
- [60] M. Kubat y S. Matwin, «Addressing the Curse of Imbalanced Training Sets: One-Sided Selection», 1997.
- [61] T.-Y. Lin, P. Goyal, R. Girshick, K. He, y P. Dollár, «Focal Loss for Dense Object Detection», en *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980-2988. doi: [10.1109/iccv.2017.324](#).
- [62] K. Chen *et al.*, «MMDetection: Open MM-Lab Detection Toolbox and Benchmark», *arXiv preprint arXiv:1906.07155*, 2019.